

T.C.
BURSA TEKNİK ÜNİVERSİTESİ
Mühendislik ve Doğa Bilimleri Fakültesi
Bilgisayar Mühendisliği Bölümü

Doğal Dil İşleme Projesi
İsim ve Diğer Öbeklerin Saptanması (Chunking)

Ders: Doğal Dil İşleme
Dönem: 2025 – 2026 Bahar Dönemi
Grup Üyeleri: Sami Erzincanlı 23360859058
Barış Yazıcı 22360859049
Selman Çetin 21360859082

1. Giriş

Bu proje, Bursa Teknik Üniversitesi Bilgisayar Mühendisliği Bölümü 2025–2026 Bahar Dönemi Doğal Dil İşleme dersi kapsamında hazırlanmıştır.

Projenin konusu **İsim ve Diğer Öbeklerin Saptanması (Chunking)** olarak belirlenmiştir. Chunking (ya da kısmi ayrıştırma), bir cümle içindeki kelimelerin hangi sözdizimsel gruba (öbeğe) ait olduğunu belirleyen bir Doğal Dil İşleme görevidir. Bu görevde:

- **NP** (Noun Phrase / İsim Öbeği): İsimlerin oluşturduğu gruplar
- **VP** (Verb Phrase / Eylem Öbeği): Fiillerin oluşturduğu gruplar
- **ADVP** (Adverb Phrase / Zarf Öbeği): Zarfların oluşturduğu gruplar
- **PP** (Prepositional Phrase / Edat Öbeği): Edatların oluşturduğu gruplar
- **O**: Herhangi bir öbeğe dahil olmayan kelimeler

etiketleri BIO (Beginning–Inside–Outside) formatında her kelimeye atanmaktadır.

1.1. BIO Etiketleme Formatı

BIO formatında her kelime üç durumdan birinde etiketlenir:

- **B-X**: Bir X öbeğinin *başlangıç* kelimesi
- **I-X**: Bir X öbeğinin *devam* kelimesi
- **O**: Öbek dışı kelime

Örnek cümle ve CoNLL formatındaki etiketleme:

Tablo 1: CoNLL formatında örnek etiketleme

ID	FORM	CHUNK-OUTER	CHUNK-INNER	CLAUSE
1	Dün	B-ADVP	—	O
2	akşam	I-ADVP	—	O
3	toplantıdan	B-NP	B-RELCL	B-RELCL
4	erken	I-NP	I-RELCL	I-RELCL
5	çıkan	I-NP	I-RELCL	I-RELCL
6	öğrencinin	I-NP	—	O
7	,	O	—	O
8	hocasının	B-NP	B-RELCL	B-RELCL
9	önerdiği	I-NP	I-RELCL	I-RELCL
10	makaleyi	I-NP	—	O
11	kütüphanede	B-NP	—	B-COMPCL
12	dikkatlice	B-ADVP	—	I-COMPCL
13	okuduğunu	B-VP	—	I-COMPCL
14	fark	B-VP	—	O
15	ettim	I-VP	—	O
16	.	O	—	O

2. Veri Seti

2.1. Universal Dependencies Türkçe Treebank

Bu projede veri seti olarak **Universal Dependencies (UD) Turkish-BOUN Treebank** kullanılmıştır. Bu veri seti, Boğaziçi Üniversitesi tarafından hazırlanmış olup CoNLL-U formatında ayrıntılı Türkçe sözdizimsel etiketlemeler içermektedir [1].

Veri setinin temel özellikleri:

Tablo 2: Veri seti istatistikleri

Bölüm	Cümle Sayısı	Token Sayısı
Eğitim (train)	8.782	113.002
Test	979	12.210
Toplam	9.761	125.212

2.2. Veri Hazırlama

UD Treebank, CoNLL-U formatında UPOS (Universal Part-of-Speech) etiketleri içermektedir. Bu etiketler aşağıdaki kurala göre chunk etiketlerine dönüştürülmüştür:

Tablo 3: POS etiketi → Chunk etiketi dönüşüm kuralları

UPOS Etiketleri	Chunk Türü
NOUN, PROPN, PRON, DET, ADJ, NUM	NP (İsim Öbeği)
VERB, AUX	VP (Eylem Öbeği)
ADV	ADVP (Zarf Öbeği)
ADP	PP (Edat Öbeği)
PUNCT, CONJ, CCONJ, SCONJ, diğer	O

2.3. Etiket Dağılımı

Eğitim verisindeki etiket dağılımı aşağıdaki tabloda verilmiştir:

Tablo 4: Eğitim verisi etiket dağılımı

Etiket	Token Sayısı	Oran (%)
B-NP	27.690	24.50
I-NP	30.885	27.33
B-VP	18.216	16.12
I-VP	4.588	4.06
B-ADVP	4.405	3.90
I-ADVP	527	0.47
B-PP	2.222	1.97
I-PP	11	0.01
O	24.458	21.64
Toplam	113.002	100.00

3. Yöntem

3.1. Öznitelik Mühendisliği

Her kelime için aşağıdaki öznitelikler çıkarılmıştır:

- **Kelime öznitelikleri:** Kelimenin kendisi, küçük harf formu, büyük harf mi, baş harfi büyük mü, rakam mı, uzunluğu
- **Suffix (son ekler):** Son 1, 2, 3 ve 4 karakter – Türkçe eklemeli bir dil olduğundan morfolojik eklere dayalı bu öznitelikler çok kritiktir
- **Prefix (ön ekler):** İlk 2 ve 3 karakter
- **Bağlam penceresi:** Önceki 2 ve sonraki 2 kelime ile bunların özellikleri
- **Cümle sınırları:** BOS (cümle başı), EOS (cümle sonu) bayrakları

3.2. Model 1: Conditional Random Fields (CRF)

Conditional Random Fields (Koşullu Rastsal Alanlar), dizi etiketleme problemleri için tasarlanmış istatistiksel bir modeldir. Naive Bayes ve Logistic Regression'dan farklı olarak her kelimeyi bağımsız sınıflandırmak yerine, komşu etiketler arasındaki bağımlılıkları da modelleyebilir. Bu özelliği chunking gibi ardışık etiketleme görevleri için CRF'yi ideal kılmaktadır.

Model parametreleri:

- Algoritma: L-BFGS (Limited-memory Broyden–Fletcher–Goldfarb–Shanno)
- L1 düzenleme katsayısı: $C_1 = 0.05$
- L2 düzenleme katsayısı: $C_2 = 0.05$
- Maksimum iterasyon: 150

3.3. Model 2: Naive Bayes

Multinomial Naive Bayes, Bayes teoremini temel alan istatistiksel bir sınıflandırıcıdır. Özellikler arasındaki bağımsızlık varsayımı yapsa da hızlı ve basit yapısıyla temel (baseline) model olarak kullanılmaktadır. CRF ile karşılaştırma amacıyla ikinci model olarak seçilmiştir.

Model parametreleri:

- Düzleştirme katsayısı: $\alpha = 0.1$
- Öznitelik ölçekleme: MinMaxScaler (Naive Bayes negatif değer kabul etmez)

4. Sonuçlar

4.1. Model Karşılaştırması

Tablo 5: Model başarı karşılaştırması

Model	Accuracy	Macro F1	Weighted F1
CRF	0.9283	0.7755	0.9278
Naive Bayes	0.5129	0.2019	0.4357

CRF modeli, chunking gibi sıralı bağımlılıkların kritik önem taşıdığı bir görevde **%92.83 doğruluk oranı** elde etmiştir. Naive Bayes ise her kelimeyi bağımsız değerlendirdiğinden %51.29 ile sınırlı kalmıştır. Bu fark, komşu etiket bilgisinin chunking başarısındaki kritik rolünü açıkça göstermektedir.

4.2. CRF Sınıf Bazlı Metrikler


Tablo 6: CRF modeli – sınıf bazlı sonuçlar

Etiket	Precision	Recall	F1-Score	Destek
B-ADVP	0.8212	0.8097	0.8154	431
B-NP	0.9245	0.9316	0.9280	2.996
B-PP	0.9528	0.8441	0.8952	263
B-VP	0.9100	0.8784	0.8939	2.048
I-ADVP	0.7692	0.6122	0.6818	49
I-NP	0.9186	0.9497	0.9338	3.456
I-PP	0.0000	0.0000	0.0000	1
I-VP	0.8699	0.8210	0.8447	391
O	0.9864	0.9864	0.9864	2.575
Accuracy		0.9283		12.210
Macro avg	0.7947	0.7592	0.7755	12.210
Weighted avg	0.9279	0.9283	0.9278	12.210

Not: I-PP sınıfı test setinde yalnızca 1 örnekle temsil edildiğinden sıfır F1 skoru elde edilmiştir. Bu istatistiksel olarak anlamlı değildir.


4.3. Grafiksel Sonuçlar

4.3.1 CRF Karmaşıklık Matrisi




Şekil 1: CRF modeli karmaşıklık matrisi (Confusion Matrix). Köşegen üzerindeki yüksek değerler modelin başarılı sınıflandırma yaptığını göstermektedir.

4.3.2 CRF Sınıf Bazlı Metrik Grafiği




Şekil 2: CRF modeli – her sınıf için Precision, Recall ve F1-Score değerleri.

4.3.3 Naive Bayes Karmaşıklık Matrisi



Şekil 3: Naive Bayes modeli karmaşıklık matrisi. Köşegen dışı değerlerin yüksekliği modelin birçok sınıfı birbirine karıştırdığını göstermektedir.

4.3.4 Model Karşılaştırma Grafiği



Şekil 4: CRF ve Naive Bayes modellerinin Accuracy, Macro F1 ve Weighted F1 skorları karşılaştırması.

4.4. Tartışma

CRF modeli tüm metriklerde Naive Bayes'i önemli ölçüde geride bırakmıştır. Bu sonucun temel nedenleri şöyle sıralanabilir:

1. **Dizi bağımlılığı:** CRF, bir kelimenin etiketini belirlerken komşu etiketleri de göz önünde bulundurur. Chunking'de bir NP öbeği içindeki kelimelerin birbirini takip etmesi gibi dizi kalıpları bu sayede yakalanabilmektedir.
2. **Türkçe'ye uygunluk:** Türkçe eklemeli bir dildir; kelimenin sonu çoğu zaman sözdizimsel rolünü belirler. CRF'nin suffix özniteliklerini etkili biçimde kullanması Türkçe'de özellikle faydalı olmuştur.
3. **Naive Bayes'in sınırlılıkları:** Naive Bayes bağımsızlık varsayımı nedeniyle dizi içi bağımlılıkları modelleyemez. Bu nedenle özellikle B-VP, I-VP, I-ADVP gibi ardışıklık gerektiren sınıflarda başarısız olmuştur.

5. Sonuç

Bu projede Türkçe metinler için chunking görevi gerçekleştirilmiştir. Universal Dependencies Turkish-BOUN Treebank kullanılarak 9.761 cümlelik bir veri seti hazırlanmıştır. İki farklı makine öğrenmesi modeli eğitilmiş ve karşılaştırılmıştır:

- **CRF modeli %92.83 doğruluk oranı** elde ederek chunking için güçlü bir performans sergilemiştir. Özellikle B-NP (%93 F1), I-NP (%93 F1) ve O (%99 F1) sınıflarında çok başarılı sonuçlar alınmıştır.
- **Naive Bayes modeli %51.29 doğruluk oranı** ile kalmıştır. Dizi bağımlılıklarını yakalayamaması bu düşük performansın temel nedenidir.

Sonuçlar, dizi etiketleme problemlerinde CRF gibi bağlam duyarlı modellerin klasik istatistiksel modellere olan üstünlüğünü açıkça ortaya koymaktadır.

5. Kaynaklar

- [1] Türk, U., Atmaca, F., Özateş, Ş. B., Köse, A., Küçükçiloğlu, S., Eryiğit, G., & Özgür, A. (2022). *Resources for Turkish Dependency Parsing: Introducing the BOUN Treebank and the BoAT Annotation Tool*. Language Resources and Evaluation, 56, 579–625.
- [2] Lafferty, J., McCallum, A., & Pereira, F. (2001). *Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data*. In Proceedings of ICML, 282–289.
- [3] Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing* (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>